PROJETO INTEGRADOR I · CIÊNCIA DE DADOS E MACHINE LEARNING

Predição de Churn e Retenção de Alunos em Academias

Modelo de alerta antecipado (early-warning) que estima a probabilidade de cancelamento de plano a partir do histórico de parcelas dos alunos.

Centro Universitário de Brasília (CEUB) · Brasília — Junho / 2026

CONTEXTO

O problema de negócio

Academias têm receita pouco previsível por causa da inadimplência e da evasão de clientes (churn). Sem ação proativa, a perda financeira é recorrente.

Receita imprevisível

Inadimplência e cancelamentos comprometem o fluxo de caixa, vital para a operação.

Ação tardia

A equipe só percebe o risco após o vencimento — quando reverter já é difícil.

Dado bruto, sem inteligência

O histórico transacional existe, mas não é transformado em decisão acionável.

A oportunidade: aplicar Machine Learning para prever o risco de cancelamento antes que ele aconteça, transformando dados de parcelas em ações de retenção.

OBJETIVOS

O que o projeto se propõe a entregar

OBJETIVO GERAL

Desenvolver um sistema preditivo capaz de identificar a probabilidade de cancelamento de um aluno, integrando um modelo de Machine Learning a uma infraestrutura de dados.

OBJETIVOS ESPECÍFICOS

Engenharia & tratamento dos dados

Limpar e estruturar o histórico de mensalidades e cadastros em uma base pronta para modelagem.

Treinar e avaliar um classificador

Construir um modelo de classificação binária que prevê o status do aluno (cancela / permanece).

Arquitetura de dados de alta performance

Estruturar armazenamento híbrido (relacional + NoSQL) — evolução prevista para o Projeto II.

METODOLOGIA

Design Science Research (DSR)

A pesquisa é guiada pela DSR: parte de um problema real e produz um artefato avaliável, com cinco etapas encadeadas.

1

Problema relevante

Identificar padrões de risco antes do vencimento da parcela.

2

Construção do artefato

Pipeline de dados + modelo de classificação binária por zona de risco.

3

Avaliação

Validação por métricas (F1, ROC-AUC) e impacto na antecipação de cobrança.

4

Construção científica

Viabilidade de MLOps e bancos modernos em pequenos e médios negócios.

5

Comunicação

Relatório técnico e demonstração do artefato em sala (endpoint de predição).

FORMULAÇÃO DO PROBLEMA

Como o churn foi modelado

Unidade de análise: o aluno

Uma linha por matrícula. Todo o histórico de parcelas é condensado em um único registro por aluno.

Alvo (churn): **1** se o aluno tem ≥ 1 parcela **Cancelada** · **0** caso permaneça.

Anti-vazamento (data leakage)

Para quem cancelou, os atributos usam apenas as parcelas **anteriores ao cancelamento** (janela de observação).

A parcela cancelada nunca vira atributo — senão o modelo apenas ***"decoraria" o rótulo*** em vez de aprender o comportamento de risco.

Janela de observação por aluno



- Só médias e taxas — nunca contagens de parcelas (seriam proxy do rótulo).
- Sem indicador de "ausência de pagamento"; imputação pela mediana.

ENGENHARIA DE DADOS

A base de dados

Exports do sistema da academia: matrícula, modalidades, histórico de parcelas, faturamento, pagamentos e status do contrato.

4.364
ALUNOS ÚNICOS

8.489
CONTRATOS

71.321
PARCELAS

4 anos
2022 → 2026

PIPELINE DE LIMPEZA E PADRONIZAÇÃO

Cabeçalho automático

Detecta a linha do cabeçalho real; funciona na amostra e na base completa.

Tipos & nulos

Renomeia colunas, trata "-" como ausente, converte valores e datas.

Higienização

Valida telefones e separa strings agrupadas; remove duplicatas.

PRIVACIDADE · SEÇÃO 3.1 DO NOTEBOOK

Adequação à LGPD — anonimização

A base traz dados pessoais reais (nome e telefone), protegidos pela **Lei nº 13.709/2018 (LGPD)**. Como o objetivo é prever churn — não identificar pessoas — os dados são anonimizados logo após a limpeza.

id_aluno artificial

Identificador estável gerado da matrícula (factorize). Substitui nome e matrícula real — surrogate key sem tabela de-para persistida.

Telefone descartado

Guarda-se apenas a quantidade de números (n_telefones), um sinal não identificável; os números em si são removidos.

Remoção de PII

Nome, telefone, matrícula original e nome da academia são excluídos do DataFrame antes da modelagem.

Resultado: nenhum atributo identifica diretamente um aluno, e as saídas salvas do notebook ficam livres de dados pessoais.

ENGENHARIA DE ATRIBUTOS

Uma linha por aluno: os atributos

De 71 mil parcelas a uma base com 4.364 linhas e 12 colunas. Os atributos vêm de sinais que antecedem o cancelamento.

Comportamento de pagamento

Calculado só sobre parcelas pagas — que por definição ocorrem antes do cancelamento.

- **`atraso_medio_dias`** — dias médios entre vencimento e pagamento
- **`pct_em_dia`** — % de parcelas pagas em dia

Perfil estático (na adesão)

Conhecido já no momento da matrícula, sem risco temporal.

modalidade · **plano** · **recorrência** · **forma de pagamento** · **valor médio** · **nº modalidades** · **nº telefones** · **resp. próprio**

⚠ **Decisões anti-leakage:** a situação “Cancelado” nunca é atributo; nada de contagens de parcelas (censura vira proxy do rótulo) — apenas médias e taxas.

ANÁLISE EXPLORATÓRIA (EDA)

O que os dados revelam

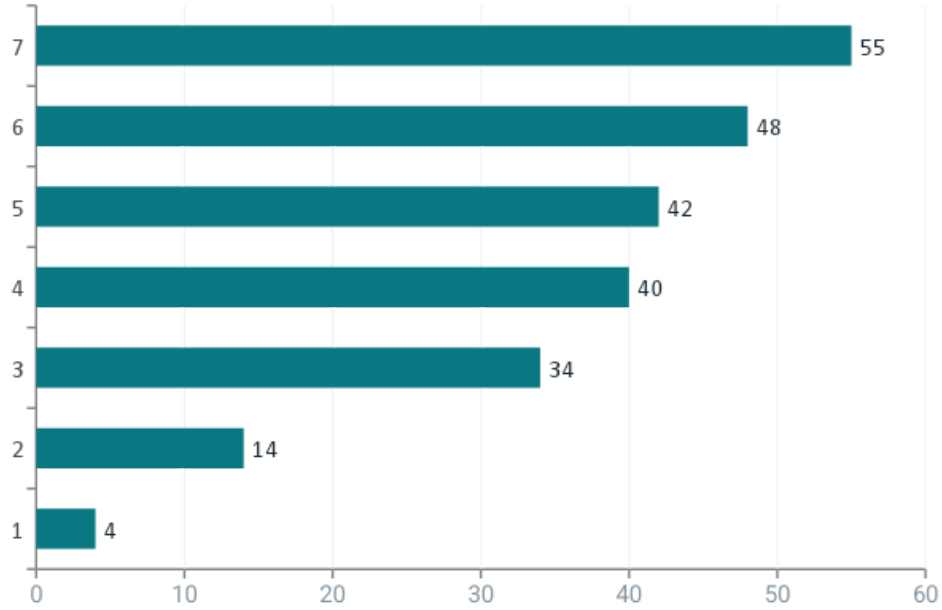
41,5% **taxa de churn**
base equilibrada — sem rótulo raro

Recorrência paga
Planos recorrentes / cartão recorrente concentram o maior churn (~55%).

Débito automático fideliza
Conta bancária e cheque têm o menor churn (4–14%).

Modalidade importa
Lutas e “Outros” cancelam mais; natação e crosstraining, menos.

Taxa de churn por forma de pagamento



PREPARAÇÃO PARA MODELAGEM

Pipeline à prova de vazamento

Todo o pré-processamento vive dentro de um Pipeline do scikit-learn, ajustado só no treino — sem contaminar o teste.

Split estratificado

Treino 3.273 · Teste 1.091 — mantém a proporção de churn nas duas partições.

›

Numéricos

Imputação (mediana) + padronização (StandardScaler) nas 6 variáveis numéricas.

›

Categóricos

One-Hot Encoding nas 4 variáveis categóricas (modalidade, plano, recorrência, pagamento).

›

ColumnTransformer + Pipeline

Encapsula tudo: o mesmo objeto transforma e prevê, evitando vazamento.

Por que importa: estatísticas de imputação e escala são aprendidas apenas no treino. A divisão estratificada garante que treino e teste tenham a mesma taxa de churn.

MODELAGEM

Cinco algoritmos em disputa

Comparamos cinco classificadores. O desbalanceamento é tratado com class_weight='balanced' (ou scale_pos_weight no XGBoost) — sem bibliotecas extras de oversampling.

Regressão Logística

Linha de base interpretável; razão de chances por atributo.

Árvore de Decisão

Regras simples e legíveis; tende a recall alto e precisão menor.

Random Forest

Ensemble de árvores; robusto e estável.

Gradient Boosting

Boosting sequencial; forte e equilibrado.

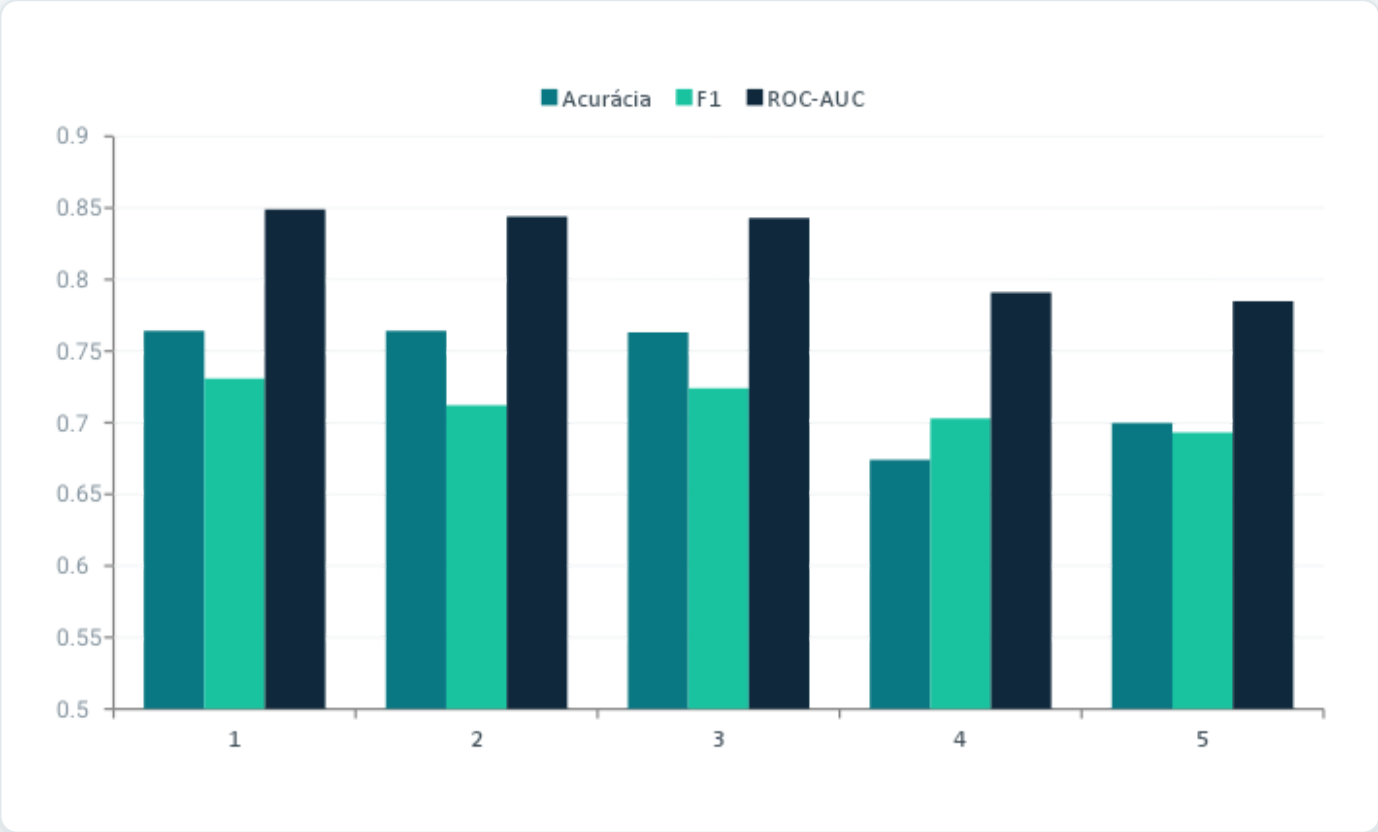
XGBoost

Boosting otimizado.

MELHOR

Tratamento de classes: pesos balanceados penalizam mais o erro na classe minoritária (quem cancela), priorizando capturar churn real.

Comparação de métricas



Vencedor

XGBoost

0,849	ROC-AUC
0,731	F1-SCORE
0,773	RECALL (CHURN)

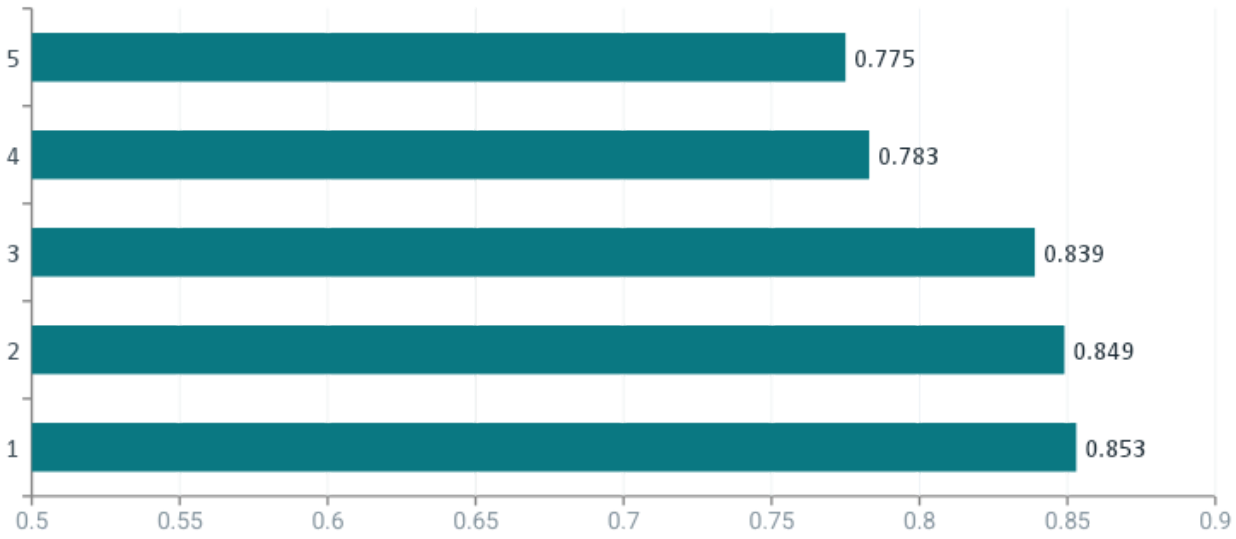
Maior ROC-AUC do estudo, com recall alto para quem cancela.

RESULTADOS · VALIDAÇÃO CRUZADA (5 FOLDS)

Estabilidade das métricas

ROC-AUC médio em validação cruzada estratificada (StratifiedKFold). O desvio-padrão baixo (≤ 0,013) indica que o desempenho não depende de um único recorte de dados.

ROC-AUC médio (validação cruzada)



0,853

XGBOOST CV

± 0,013 — topo e ainda estável.

≤ 0,013

DESVIO MÁXIMO

Variação pequena entre os 5 folds.

5 folds

ESTRATIFICADOS

Churn preservado em cada dobra.

MELHOR MODELO · XGBOOST

Matriz de confusão (teste, 1.091 alunos)



Relatório de classificação

Classe	Precisão	Recall	F1	Apoio
Permaneceu	0,82	0,76	0,79	638
Cancelou	0,69	0,77	0,73	453
Acurácia			0,76	1.091

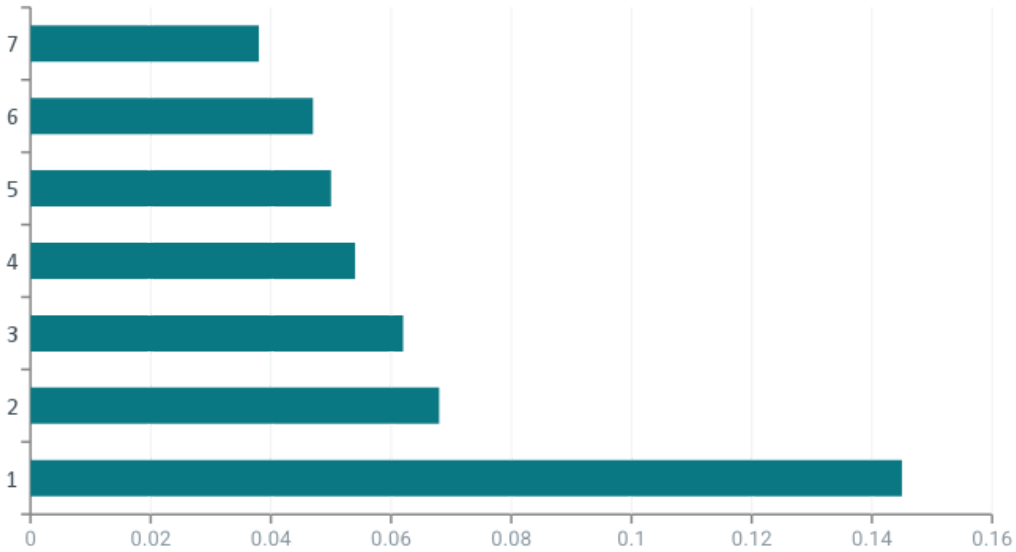
Leitura de negócio: de 453 alunos que cancelaram, o modelo sinalizou 349 a tempo (recall 0,77). Os 153 falsos positivos viram, no máximo, um contato de retenção a mais — custo baixo diante do churn evitado.

INTERPRETABILIDADE

O que dirige o churn

Importância de atributos (XGBoost), importância por permutação e razão de chances da Regressão Logística convergem para os mesmos sinais.

Atributos mais importantes — XGBoost



Razão de chances (Reg. Logística)

Aumenta o risco de churn

Plano recorrência julho	2,4×
Plano Gold recorrência	2,2×
Pagamento em cheque	1,9×
Maior atraso médio	1,6×

Reduz o risco de churn

Débito em conta bancária	0,17×
Plano natação/hidro 1-3x	0,22×
Plano Gold (à vista)	0,47×
Maior % pago em dia	↓

AVALIAÇÃO CRÍTICA

Limitações & honestidade metodológica

Janela de parcelas (8–18)

Ao cancelar, o sistema marca todas as parcelas futuras como “Cancelado” de uma vez. Boa parte do histórico de quem cancelou fica antes da parcela 8 — fora do arquivo.

Métricas otimistas nesta amostra

Por isso os números aqui são ilustrativos: “não ter pagamento observado” já sinaliza churn nesta janela. Na base completa (~70k), o modelo se apoia em comportamento real.

Dinâmica econômica externa

Sazonalidade macroeconômica e variações no poder de compra ao longo dos anos ainda não entram no modelo.

Por que isso é uma força: reconhecer o viés da amostra e parametrizar o notebook para a base completa mostra rigor metodológico — o pipeline já está pronto para escalar sem alterações de código.

TECNOLOGIA

Ferramentas & arquitetura

STACK ATUAL (PROJETO I)

Python

Linguagem central de análise e modelagem.

Scikit-Learn · Pandas · XGBoost

Pré-processamento, pipelines e classificação.

Matplotlib · Seaborn

EDA, gráficos de desempenho e diagnóstico.

Notebook parametrizado: trocar DATA_PATH roda na base completa sem mudar o código.

EVOLUÇÃO — PROJETO II

- **API & Deploy com Flask**
  Expor o modelo como endpoint de predição em produção.
- **MongoDB (NoSQL)**
  Armazenar interações de CRM de forma não relacional.
- **Redis (cache)**
  Respostas de baixa latência para alta performance.
- **Ingestão em tempo real**
  Pipeline automatizado de dados na nuvem.

CONCLUSÃO

Um artefato ponta a ponta, do dado bruto à decisão de retenção

Contribuição

Arquitetura moderna ponta a ponta — da engenharia de dados ao modelo — aplicada a um problema real de gestão de academias.

Resultado

XGBoost com ROC-AUC 0,849 e recall 0,77 para quem cancela, validado por validação cruzada estável.

Responsabilidade

Anonimização sob a LGPD e rigor anti-vazamento garantem um modelo ético e honesto.

Próximo passo: rodar o pipeline na base completa (~70k) e publicar o endpoint de predição (Flask + MongoDB + Redis) no Projeto II.

Obrigado! · Perguntas?